

Reporte Técnico - Clasificación de Prendas

1. Descripción del Dataset

El dataset está compuesto por imágenes de prendas de vestir clasificadas en tres categorías: Pantalón, Playera y Sudadera. Fuente: Dataset se descargó de Kaggle.com y fue organizado manualmente en carpetas. Diccionario de datos: - Imagen: archivo .jpg o .png - Clase: etiqueta categórica (0=Pantalón, 1=Playera, 2=Sudadera) Supuestos: - Las imágenes están correctamente etiquetadas. - Todas las imágenes fueron redimensionadas a 64x64 píxeles.

2. Proceso de limpieza y estandarización

- Eliminación de imágenes corruptas o no legibles. - Redimensionamiento a tamaño uniforme (64x64). - Conversión a escala numérica (flatten). - Normalización de valores de píxeles (0-255). - Codificación de variables categóricas a valores numéricos.

3. Estrategia de versionamiento

Se utilizó Git como sistema de control de versiones. Cambios documentados en: - CHANGELOG.md - README.md Cada versión incluye: - Ajustes en modelos - Cambios en parámetros - Mejora en métricas

4. Visualizaciones relevantes

- Matriz de confusión por modelo - Comparación de accuracy y F1-score - Distribución del dataset Estas visualizaciones permiten identificar: - Desbalance de clases - Errores de clasificación - Rendimiento relativo entre modelos

5. Modelos entrenados. Se presentan los modelos utilizados junto con su flujo de procesamiento interno

En este proyecto se implementaron dos algoritmos de aprendizaje supervisado: Regresión Logística y Random Forest, utilizados para la clasificación de prendas de vestir.

5.1 Regresión Logística

La regresión logística es un modelo de clasificación lineal que calcula una combinación ponderada de las variables de entrada. Posteriormente, aplica la función softmax para obtener probabilidades por clase. El modelo aprende ajustando los pesos W mediante optimización (descenso de gradiente), minimizando una función de pérdida logarítmica (log-loss).

5.1 Regresión Logística

Flujo: Regresión Logística

Entrada: Imagen (vectorizada)

Multiplicación lineal ($W \cdot X + b$)

Función Softmax

Cálculo de probabilidades

Clase con mayor probabilidad

La regresión logística transforma la entrada mediante una combinación lineal y aplica la función softmax para obtener probabilidades por clase.

5.2 Random Forest

Random Forest es un modelo de ensamblado basado en múltiples árboles de decisión. Cada árbol se entrena con una muestra aleatoria del dataset y realiza predicciones independientes. El resultado final se obtiene mediante votación mayoritaria. Este enfoque reduce el sobreajuste y mejora la capacidad de generalización.

5.2 Random Forest

Flujo: Random Forest

Entrada: Imagen (vectorizada)

Bootstrap Sampling

Múltiples Árboles de Decisión

Predicciones individuales

Votación mayoritaria

Clase final

Random Forest construye múltiples árboles de decisión y utiliza votación mayoritaria para determinar la clase final.

5.3 Comparación de modelos

Regresión logística es un modelo lineal eficiente e interpretable, mientras que Random Forest es más complejo y capaz de capturar relaciones no lineales en los datos.


6. Configuración de hiperparámetros

Regresión Logística: - C = 1.0 - max_iter = 1000 Random Forest: - n_estimators = 100 - max_depth = 10


7. Evaluación de modelos y resultados

Se presentan las métricas, matrices de confusión, distribución del dataset y comparación entre modelos.


Distribución del Dataset




Comparación de Modelos



Matriz de Confusión - Logistic Regression



Matriz de Confusión - Random Forest



Classification Report - Logistic Regression

	precision	recall	f1-score	support
0	0.78	0.82	0.80	104
1	0.66	0.72	0.69	85
2	0.78	0.68	0.73	111
accuracy			0.74	300
macro avg	0.74	0.74	0.74	300
weighted avg	0.74	0.74	0.74	300

Classification Report - Random Forest

	precision	recall	f1-score	support
0	0.86	0.86	0.86	104
1	0.77	0.73	0.75	85
2	0.81	0.85	0.83	111
accuracy			0.82	300
macro avg	0.81	0.81	0.81	300
weighted avg	0.82	0.82	0.82	300

8. Comparación de resultados

Se compararon ambos modelos utilizando métricas estándar. Random Forest mostró mejor desempeño general en F1-score y accuracy.

9. Evidencia de MLflow

MLflow fue utilizado para: - Registro de experimentos - Guardado de métricas - Almacenamiento de modelos - Trazabilidad de resultados Se generaron runs para ambos modelos con métricas completas.

10. Reflexión sobre deuda técnica y MLOps

El proyecto presenta posibles mejoras en: - Automatización del pipeline - Balanceo de clases - Optimización de hiperparámetros - Despliegue del modelo MLflow facilita la adopción de prácticas MLOps al permitir trazabilidad y reproducibilidad.